

MEME KANSERİNİN SINIFLANDIRILMASI, TESPİTİ VE SEGMENTASYONU

İbrahim Ethem RONA (*)

Özet

Meme kanseri dünya üzerinde en çok rastlanan kanser türlerindendir. Her sekiz kadından birine meme kanseri tanısı konulmaktadır. Erken teşhis, erken ölümlerin sayısını azaltmaya yardımcı olur. Bu yüzden meme kanseri belirtileri konusunda hassas davranılması çok önemlidir. Bu makalede, ultrason taraması kullanılarak meme kanserinin tıbbi görüntülerini gözden geçirmektedir. Meme Ultrason Veri Seti üç sınıfa ayrılmıştır: iyi huylu, kötü huylu ve normal görüntüler. Meme ultrason görüntüleri, makine öğrenimi ve derin öğrenme ile birleştirildiğinde meme kanserinin sınıflandırılması, tespiti ve segmentasyonu konusunda optimal sonuçlar üretir.

Anahtar Kelimeler: Meme Kanseri, Makine Öğrenimi, Derin Öğrenme, Evrişimli Sinir Ağları, Sınıflandırma, Meme Kanseri Ultrason Görüntüleri

CLASSIFICATION, DETECTION AND SEGMENTATION OF BREAST CANCER

Abstract

Breast cancer is one of the most common types of cancer in the world. One out of every eight women is diagnosed with breast cancer. Early detection helps to reduce the number of premature deaths. That's why it's very important to be sensitive about the symptoms of breast cancer. In this article, she reviews medical images of breast cancer using ultrasound scanning. The Breast Ultrasound Dataset is divided into three classes: benign, malignant and normal images. Breast ultrasound images, when combined with machine learning and deep learning, produce optimal results in the classification, detection and segmentation of breast cancer.

Keywords: Breast Cancer, Machine Learning, Deep Learning, Convolutional Neural Networks, Classification, Ultrasound Images of Breast Cancer

Giriş

Meme kanseri, dünyadaki kadınlar arasında ikinci büyük ölüm nedenidir. Meme kanserinin erken ve doğru teşhisi, hayat kurtarmak için doğru tedavi planlaması için önemlidir (Sahu, vd., 2024). Ultrasona dayalı bilgisayar destekli tanı (CAD) sistemleri geliştirilmiş ve meme kanseri taramasında yaygın olarak desteklenmiştir. Düşük kontrast ve benek seslerinin özellikleri nedeniyle, CAD sistemlerinin en önemli adımlarından biri olan meme ultrasonu görüntü segmentasyonu her zaman zor olmuştur (Zhao, vd., 2023, s. 1). İlk çalışmalarda görüntü işleme teknikleri ile manuel olarak elde edilen özellikler kullanılmıştır. Meme lezyonları, destek vektör makinesi (SVM), k-en yakın komşular (KNN) ve ikili karar ağacı gibi

yöntemlere aktararak sınıflandırıldı. Son zamanlarda, derin öğrenmenin gelişmesiyle birlikte, ultrason görüntülerinde meme lezyonu sınıflandırması ve segmentasyonu için evrilmiş sinir ağları (CNN) dahil olmak üzere derin öğrenme yöntemleri, hiyerarşik yapıların ve özelliklerin çıkarılması nedeniyle segmentasyon görevlerinde popülerlik kazanmıştır (Üzen, 2024).

Bu çalışmada, meme kanseri görüntülerini, iyi huylu, kötü huylu ve normal türler olarak sınıflandırabilen farklı makine öğrenimi teknikleri ile derin öğrenme tekniklerinin karşılaştırılması yapılmıştır. Bölüm 2’de materyal ve metottan bahsedilmiştir. Bu bölümde, deneysel çalışmada kullanılan veri setinden ve uygulaması yapılan makine öğrenimi ve derin öğrenme tekniklerinden bahsedilmiştir. Bölüm 3’te deneysel çalışmalar, Bölüm 4’te ise çalışmanın sonuç kısmına yer verilmiştir.

2. Materyal ve Metot


2.1. Materyal

Veriler popüler veri seti olan Kaggle’den alınmıştır. Kadın hastalardan elde edilen görüntüler bulunmaktadır. Veri setindeki, her bir görüntü boyutu farklı piksellerden ve 1578 görüntüden oluşmaktadır. Görüntüler gri tonlamalı ve PNG formatındadır. Görüntüler iyi huylu, kötü huylu ve normal olmak üzere üç sınıfa ayrılmıştır. Her sınıftaki görüntülerin sayısı Tablo 1’de gösterilmektedir.

Kanser Türleri	Öge Sayısı
İyi Huylu	891
Kötü Huylu	421
Normal	266
Toplam Öge Sayısı	1578

Tablo 1 Meme kanseri veri setinde bulunan türlere ait görüntü sayıları ve toplamı

Şekil 1’ de bu veri kümesinden iyi huylu, kötü huylu ve normal vakaya ait görüntüler gösterilmektedir.



Şekil 1 İyi huylu, kötü huylu ve normal vakaya ait orijinal görüntüler


Her meme kanseri kategorisi türü için üç klasör bulunmaktadır. Her klasörde kendi sınıfının görüntüleri bulunur. Sınıfın adını ve resmin numarasını içerir. Her bir klasörde bulunan görüntülere ait maskeli görüntüleri bulunmaktadır. Ayrıca sınıfın adı, _maske eklenerek orijinal görüntüler ile aynı adı taşımaktadır. Şekil 2’de sınıflara ait maskeli görüntüleri gösterilmektedir.



Şekil 2 İyi huylu, kötü huylu ve normal vakaya ait orijinal görüntülerin maskeli görüntüleri

2.2. Metot

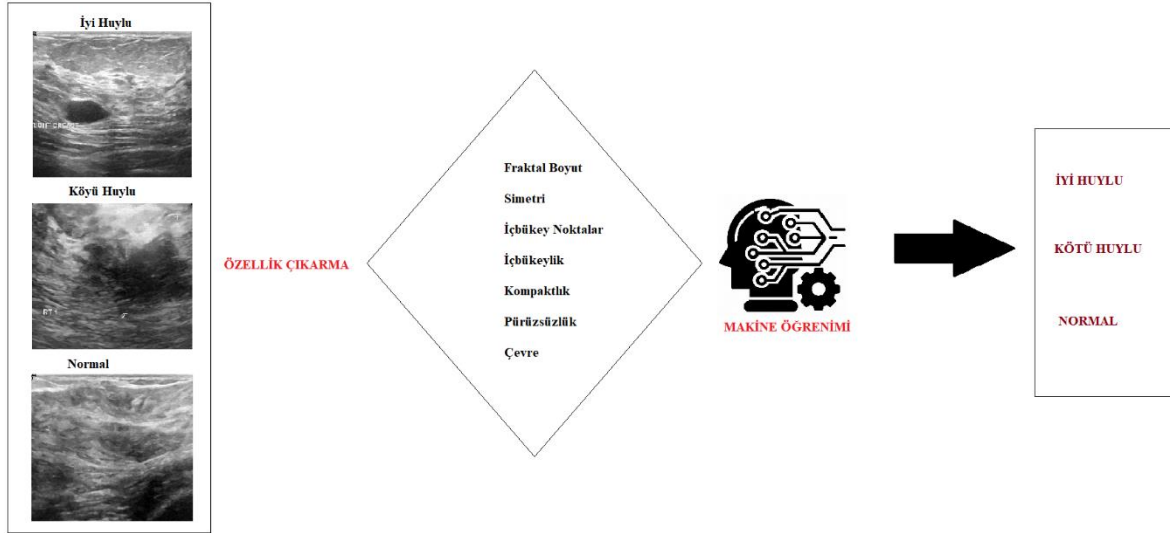
Makine öğrenimi, elle programlanmak yerine *eğitilirler*. Göreve yönelik verilen örneklerle bakarak istatistiksel örüntüleri ortaya çıkartıp görevi otomatikleştirecek kuralları ortaya koyar.



Şekil 3 Makine Öğrenmesi

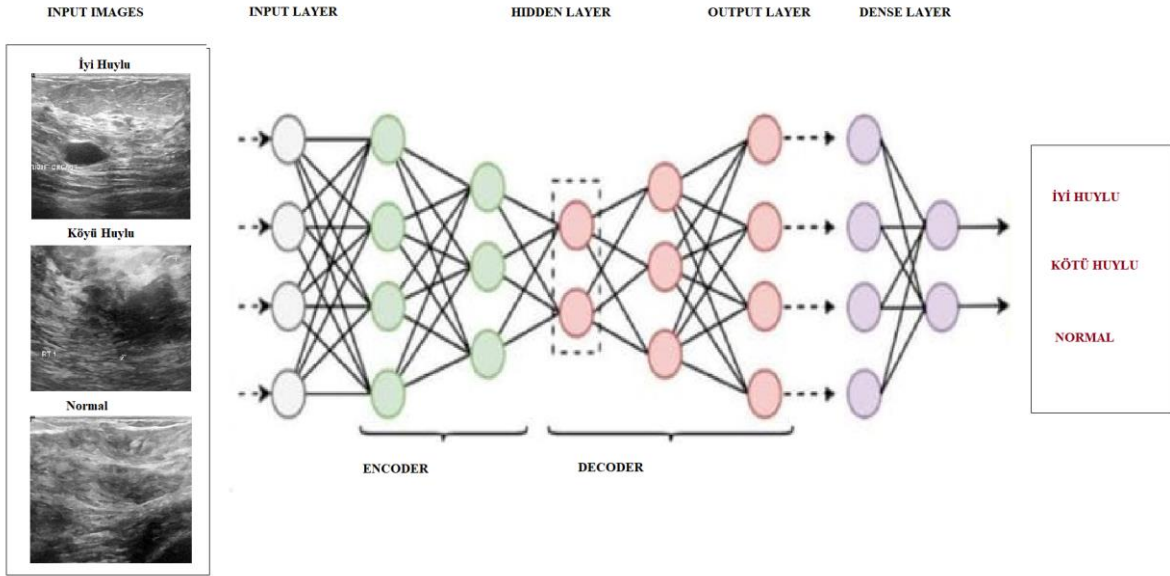
Derin öğrenme ise, birbirini takip eden katmanlarda veriler işlenirken giderek artan şekilde daha kullanışlı gösterimler elde edebilen makine öğrenmesinin bir alt alanıdır. Derin derken kastedilen derin öğrenmenin birtakım derin bilgiler elde etmesi değil, birbirini takip eden gösterim katmanlarını ifade etmesidir. Sonuç olarak; makine öğrenmesi ve özellikle derin öğrenme daha az matematik tabanlı olup daha çok mühendislik odaklıdır. Teorik olmaktan çok gözleme ve pratik programlamaya dayanmaktadır (Chollet, 2019, s. 5-8).

Bu çalışmada, meme kanseri görüntülerini, iyi huylu, kötü huylu ve normal türler olarak sınıflandırabilen farklı makine öğrenimi teknikleri ile derin öğrenme tekniklerinin karşılaştırılması yapılmıştır. Makine öğrenimi tekniklerinden 3 farklı teknik (Random Forest, Decision Tree ve KNN) ve derin öğrenme tekniği olan Evrişimli Sinir Ağları (CNN) uygulanmıştır. Şekil 4'te meme kanseri türlerinin makine öğrenimi gösterimi bulunmaktadır.



Şekil 4 Meme kanseri türlerinin makine öğrenimi gösterimi

Şekil 5' te meme kanseri türlerinin derin öğrenme sinir ağı gösterimi bulunmaktadır.

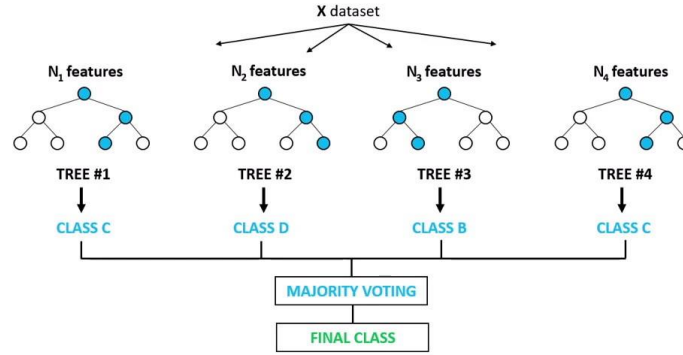


Şekil 5 Meme kanseri türlerinin derin öğrenme sinir ağı gösterimi

2.2.1. Rastgele Orman Sınıflandırıcısı

Rastgele orman (RF) modelleri, bir dizi regresyon karar ağacından elde edilen sonuçları birleştirerek çıktı tahminleri yapan makine öğrenimi modelleridir. Her ağaç bağımsız olarak oluşturulur ve ormandaki tüm ağaçların aynı dağılıma sahip olduğu girdi verilerinden örneklenen rastgele vektöre bağlıdır. Ormanlardan elde edilen tahminlerin ortalaması, önyükleme, toplama ve rastgele özellik seçimi kullanılarak alınır (Williams, vd., 2020, s. 1639-1644).

Random Forest Classifier




Şekil 6 Rastgele Orman Sınıflandırıcısı

2.2.2. KNN

K-En Yakın Komşular (KNN) regresyon modeli, anlaşılması kolay bir yöntemdir ve yeni bir gözlemin değerini tahmin etmek için eğitim veri kümesindeki K en yakın veri noktalarını (giriş özelliklerinde en benzer) kullanır. KNN regresyonu, hisse senedi fiyatlarını tahmin etmek, konut fiyatlarını tahmin etmek ve hava modellerini tahmin etmek gibi çeşitli uygulamalarda yaygın olarak kullanılmaktadır (Akt. Sumaylı, 2023).

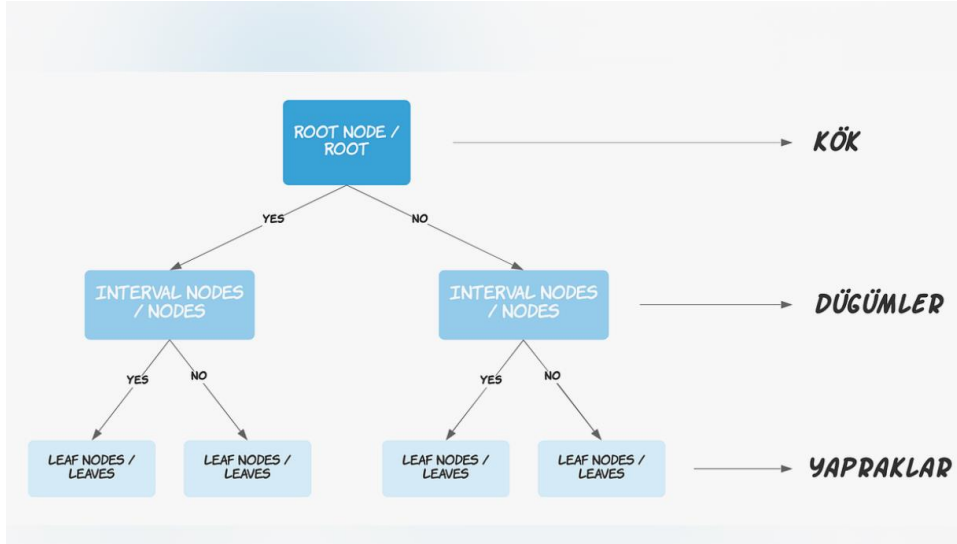
5



Şekil 7 KNN

2.2.3. Karar Ağaç Sınıflandırıcısı

Karar ağaçları (DT), özellik ve hedefe göre karar düğümleri (Decision Nodes) ve yaprak düğümlerinden (Leaf Nodes) oluşan ağaç yapısı formunda bir model oluşturan bir sınıflandırma yöntemidir. Karar ağacı algoritması, veri setini küçük ve hatta daha küçük parçalara bölerek geliştirilir. Bir karar düğümü bir veya birden fazla dallanma içerebilir. İlk düğüme kök düğüm (Root Node) denir. Bir karar ağacı hem kategorik hem de sayısal verilerden oluşabilir (Uzun, E.T. 2024).

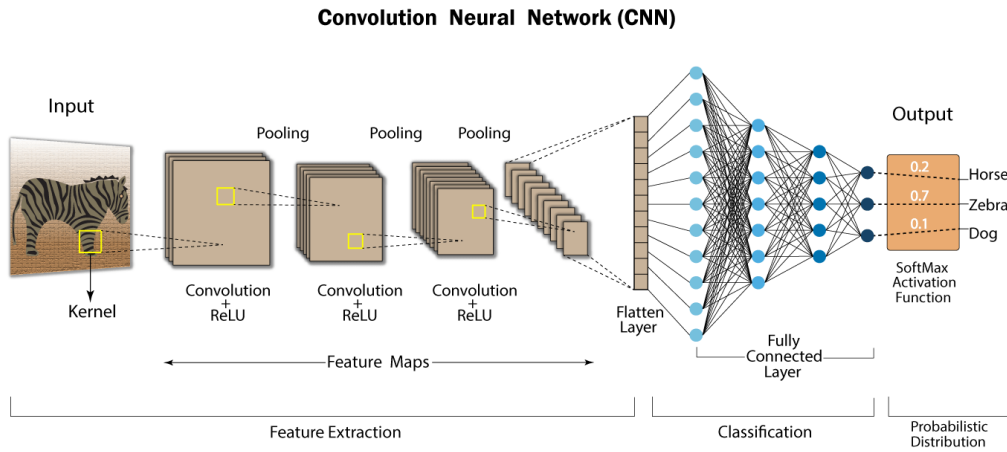


Şekil 8 Karar Ağacı Modeli

2.2.4. Evrilmiş Sinir Ağları (CNN)

Evrilimsel sinir ağları, derin öğrenmenin bir alt dalıdır. Genellikle görsel bilginin analiz edilmesinde kullanılır. Bunu evrilim bir diğer adıyla konvolüsyon adı verilen matematik işlemiyle yapar. Bu işlem özel bir lineer işlem türüdür (Öksüz, 2021).


Evrilimsel sinir ağları katmanlardan oluşan bir tür sinir ağıdır. Şekil 9'da gösterilmektedir.



Şekil 9 Evrilimli Sinir Ağları (CNN)

Convolution Katmanı

Bu katman CNN'nin ana yapı taşıdır. Burada filtreler (Filter, Kernel) görev alır. Filtreler görsel boyunca kaydırılır. Kaydırma sırasında görselin değerleri ile filtredeki değerler çarpılır ve elde edilen değerler toplanır ve net sonuç bulunur. Örnek olarak elimizde 5x5'lik bir resim ve 3x3'lük bir filtre bulunsun. Filtre resim boyunca her seferinde bir adım sağa ve her satır bitiminde 1 sütun aşağı kaydırılarak yeni görsel elde edilir. Elde edilen bu görsel 3x3 boyutunda olur. Şekil 10'da gösterilmektedir.



Şekil 10 Convolution Katmanı

Pooling (Ortaklama) Katmanı


Bu katmanın görevi, gösterimin kayma boyutunu ve ağ içindeki parametreleri ve hesaplama sayısını azaltmak içindir. Bu sayede ağdaki uyumsuzluklar kontrol edilmiş olur.

İki tür pooling yöntemi vardır; maksimum ve ortalama ortaklama. Maksimum ortaklamada amaç matrisin maksimum değerini seçer. Bu işlem algılanan özellikleri korur ve en çok kullanılandır. Ortalama ortaklamada amaç ise matrisin değerlerinin ortalaması alır. Bu işlem ise boyut azaltarak örneklenmişlik öznetelik haritası oluşturur.

Activation Katmanı

Bu katmanda Droupout fonksiyonu sayesinde ağıımızdaki bazı nöronlar rasgele olarak etkisiz hale getirilmektedir. Bu özelliğin en önemli noktası eğitim sırasında nöronlara bağımsızlık kazandırarak sistemin daha iyi verim elde etmesini sağlamasıdır. Şekil 11’da gösterilmektedir.


7



Şekil 11 Activation Katmanı

Flatting Katmanı

Bu katmanın görevi, en önemli katman olan Fully Connected Layer’ın girişindeki verileri hazırlamaktır. Genel olarak, sinir ağları, giriş verilerini tek boyutlu bir diziden alır. Bu sinir ağındaki veriler ise Convolutional ve Pooling katmanından gelen matrislerin tek boyutlu diziye çevrilmiş halidir. Şekil 12’de gösterilmektedir.



Şekil 12 Flatting Katmanı

Fully-Connected Katmanı

Bu katman ConvNet'in son ve en önemli katmanıdır. Verileri Flattening işleminden alır ve Sinir ağı yoluyla öğrenme işlemini gerçekleştirir.

3. Deneysel Çalışmalar

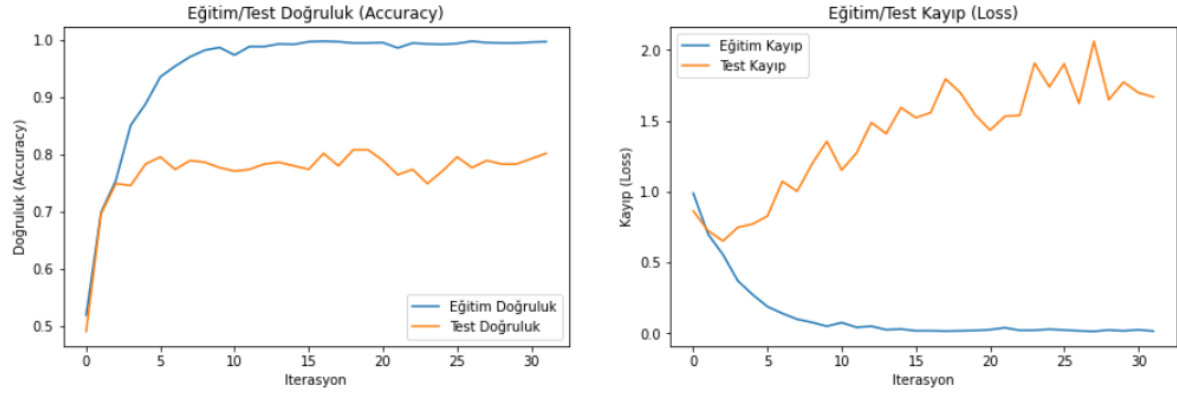
Bu çalışmada, Python 3.9 ve ilgili kütüphaneler kullanılarak yazılım işlemi gerçekleştirildi. Veriler üzerinde çeşitli işlemler yapılarak, veri artırma yöntemine başvuruldu. Öge sayısı 1578'den 1611'e çıkarıldı. Deneysel çalışmada, veriler %80 eğitim ve %20 test için ayrılmıştır. 1288 adet veri tahmin ve 323 adet veri test'e tâbi tutulmuştur.

Bu aşamada farklı makine öğrenimi tekniklerinin performansı farklı değerlendirme ölçütleri yapıldı. Farklı tekniklerin performansı, kesinlik (precision), duyarlılık (recall), F1-skoru, doğruluk (accuracy) olmak üzere dört performans ölçütü kullanılarak değerlendirildi. Bu değerler, her bir sınıf için hata matrisleri üzerinden hesaplanır (Bozkurt, 2021, s. 149-156). Tablo 2'de değerlendirme sonuçları gösterilmektedir.

Model	Kesinlik (%)	Duyarlılık (%)	F1-Skoru (%)	Doğruluk (%)
RF	77	76	75	76
KNN	68	68	68	68
DT	65	65	65	65

Tablo 2 Makine öğrenimi teknikleri performans değerleri

Aynı veri üzerinde bir evrişimli sinir ağı (CNN) olarak tasarlanmış ve bir görüntü sınıflandırma görevi için kullanılmak üzere oluşturulmuştur. Modelde ilk olarak, giriş görüntülerin piksel değerlerini 0 ile 1 arasına ölçeklemek için Rescaling katmanı uygulanmıştır. Ardından, 16, 32 ve 64 filtreden oluşan üç evrişim katmanı (Conv2D) ve ardışık olarak uygulanan maksimum havuzlama katmanları (MaxPooling2D) ile özellik çıkarımı yapılmıştır. Ayrıca overfitting'i azaltmak için bir Dropout katmanı içermektedir. Daha sonra, Flatten katmanı ve düzleştirilmiş veri, tam bağlı (dense) katmanlarını içerir. İlk tam bağlı katman 128 nöron ve son katman, sınıflandırma yapmak için 3 nörondan oluşur. Model 6,446,627 parametreye sahiptir.



Şekil 13 CNN modelinin eğitim/test doğruluk ve eğitim/test kayıp grafiği


Bu aşamada farklı makine öğrenimi ve derin öğrenme tekniklerinin doğrulukları (accuracy) değerlendirildi. Tablo 3’de değerlendirme sonuçları gösterilmektedir.

Model	Doğruluk (%)
CNN	99
RF	76
KNN	68
DT	65

Tablo 3 Makine öğrenimi ve derin öğrenme teknikleri doğruluk değerleri

Evrişimli sinir ağı modeli ile bu çalışmada en yüksek doğruluk değeri olan %99 seviyesine ulaşılmıştır. Bu modelin diğer tekniklere göre daha performanslı olduğu gözlemlenmiştir. Şekil 13’de CNN modelinin 30 iterasyon için eğitim/test doğruluk ve eğitim/test kayıp grafikleri verilmiştir. Hem test hem de eğitim doğruluk eğrileri, iterasyon sayısı arttıkça yükselen bir eğim gösterir. Kayıp eğrisi, şekil 13’de gösterildiği gibi hata oranındaki düşüşü göstermektedir. Eğitim sürecinin ve ağın öğrenilmesinin iyi bir öğrenme oranında olduğunu göstermektedir. Şekil 13’de görüldüğü gibi her iterasyonda kayıp değeri azalırken verilen eğitim seti ile doğruluk oranı artar ve öğrenme gerçekleşir.

Son olarak, modelin tahmin verilerine göre sınıflandırma yapılmıştır. Şekil 14’de gösterilmektedir.



Şekil 14 Model tahmin sınıflandırması

Sonuç

Sonuç olarak, bu çalışma meme kanserinin sınıflandırılması, tespiti ve segmentasyonu üzerine odaklanmıştır. Ultrason taraması kullanılarak elde edilen meme kanseri tıbbi görüntüler, makine öğrenimi ve derin öğrenme teknikleri ile analiz edilmiştir. Meme Ultrason Veri Seti, iyi huylu, kötü huylu ve normal görüntüler olmak üzere üç sınıfa ayrılmıştır.

Deneyisel çalışmada, farklı makine öğrenimi teknikleri (Rastgele Orman, KNN, Karar Ağaçları) ve derin öğrenme tekniği olan Evrişimli Sinir Ağları (CNN) kullanılmıştır. Performans değerlendirmesi için kesinlik, duyarlılık, F1-skoru ve doğruluk ölçütleri kullanılmıştır.

Makine öğrenimi tekniklerine göre, Rastgele Orman sınıflandırıcısının en yüksek doğruluk değerini verdiği görülmüştür. Ancak, derin öğrenme tekniği olan CNN, diğer tekniklere kıyasla çok daha yüksek bir doğruluk elde etmiştir.

Dolayısıyla, meme kanseri taramasında derin öğrenme teknikleri, özellikle Evrişimli Sinir Ağları, optimal sınıflandırma, tespit ve segmentasyon sonuçları elde etme konusunda etkili olabilir. Bu tür çalışmaların, meme kanseri teşhisinde erken tespitin önemini vurgulayarak tedavi başarı şansını artırabileceği düşünülmektedir.

Kaynakça

Abdurrahman Sumayli. (2023). Development of advanced machine learning models for optimization of methyl ester biofuel production from papaya oil: Gaussian process regression (GPR), multilayer perceptron (MLP), and K-nearest neighbor (KNN) regression models. <https://doi.org/10.1016/j.arabjc.2023.104833>

Adyasha Sahu, Pradeep Kumar Das, Sukadev Meher. (2024). An efficient deep learning scheme to detect breast cancer using mammogram and ultrasound breast images. <https://doi.org/10.1016/j.bspc.2023.105377>

Ali Öksüz. (2021). CNN Evrişimsel Sinir Ağları. <https://alioksuz.medium.com/cnn-evri%C5%9Fimsel-sinir-a%C4%9Flar%C4%B1-a938d6ccdbed>

Al-Dhabyani W, Gomaa M, Khaled H, Fahmy A. (2020). Dataset of breast ultrasound images. Data in Brief. DOI: 10.1016/j.dib.2019.104863.

Bianca Williams, Caroline Halloin, Wiebke Löbel, Ferdous Finklea, Elizabeth Lipke, Robert Zweigerdt, Selen Cremaschi. (2020). Data-Driven Model Development for Cardiomyocyte Production Experimental Failure Prediction. 1639-1644. <https://doi.org/10.1016/B978-0-12-823377-1.50274-3>

Bozkurt, F. (2021). Derin Öğrenme Tekniklerini Kullanarak Akciğer X-Ray Görüntülerinden COVID-19 Tespiti. Avrupa Bilim ve Teknoloji Dergisi, (24), 149-156. <https://dergipark.org.tr/en/download/article-file/1643941>

Chollet François. (2019). Python ile Derin Öğrenme. 1. Baskı. S. 5-8. Ankara: Buzdağı Yayınevi

Hüseyin Üzen. (2024). ConvMixer-based encoder and classification-based decoder architecture for breast lesion segmentation in ultrasound images. <https://doi.org/10.1016/j.bspc.2023.105707>

Mehmet Fatih Akça. (2020). Karar Ağaçları Makine Öğrenmesi Serisi 3. <https://medium.com/deep-learning-turkiye/karar-a%C4%9Fa%C3%A7lar%C4%B1-makine-%C3%B6%C4%9Frenmesi-serisi-3-a03f3ff00ba5>

Yu Zhao, Xiaoyan Shen, Jiadong Chen, Wei Qian, Liang Sang, He Ma. (2024). “Learning active contour models based on self-attention for breast ultrasound image segmentation, Biomedical Signal Processing and Control”. <https://doi.org/10.1016/j.bspc.2023.105816>.